



Instituto Tecnológico y de Estudios Superiores de Monterrey

Proyecto Integrador

Avance 1 : Análisis Exploratorio de Datos

Equipo 2

A01795482-Christopher Eduardo González

A01795164 - Oscar Andrés Ponce Parra

A01795663 - Paola Estrada Warn

Introducción.....	3
1. Dataset Seleccionado.....	4
Parámetros del Dataset.....	6
2. Análisis Exploratorio de Datos.....	7
2.1 Análisis de Features.....	8
2.1.1 Chute Feature.....	8
2.1.1 Cam Feature.....	8
2.1.1 Start Feature.....	8
2.1.1 End Feature.....	9
2.1.1 Label Feature.....	9
2.2. ¿Hay valores faltantes en el conjunto de datos? ¿Se pueden identificar patrones de ausencia?.....	9
2.3 ¿Cuáles son las estadísticas resumidas del conjunto de datos?.....	10
2.4. ¿Hay valores atípicos en el conjunto de datos?.....	11
2.5. ¿Cuál es la cardinalidad de las variables categóricas?.....	12
2.6. ¿Existen distribuciones sesgadas en el conjunto de datos? ¿Necesitamos aplicar alguna transformación no lineal?.....	12
2.7. ¿Se identifican tendencias temporales?.....	12
2.8. ¿Hay correlación entre las variables dependientes e independientes?.....	12
2.10. ¿Se deberían normalizar las imágenes para visualizarlas mejor?.....	13
2.11. ¿Hay desequilibrio en las clases de la variable objetivo?.....	13
4. Planteamiento de Pruebas Finales.....	15
4.1. Configuración de entorno de prueba.....	15
4.1.2 Ambientes domésticos representativos.....	15
4.1.2. Cámaras y posiciones sugeridas.....	15
4.1.3. Iluminación (condiciones de luz).....	15
4.1.4. Red y latencia.....	16

Introducción

El EDA es el puente entre la recolección de datos y el modelado predictivo, ya que ayuda a limpiar, transformar y seleccionar los datos adecuados, además de ofrecer intuiciones que guiarán el entrenamiento de modelos de *machine learning*.

En el caso del proyecto de “Guardian Eye” de nuestro proyecto integrador tenemos la ventaja de trabajar con modelos de Kaggle para llevar a cabo el entrenamiento del modelo de YOLO.

Los puntos a cubrir en este documento son:

1. Descripción del Dataset Seleccionado.
2. Análisis Exploratorio de Datos.
3. Planteamiento de Pruebas Finales.

1. Dataset Seleccionado

El dataset que se estará utilizando fue generado por un sistema de múltiples cámaras compuesto por ocho cámaras IP de bajo costo (Gadspot gs-4600) con un gran angular para cubrir toda la habitación, como se muestra en la Fig. 1.

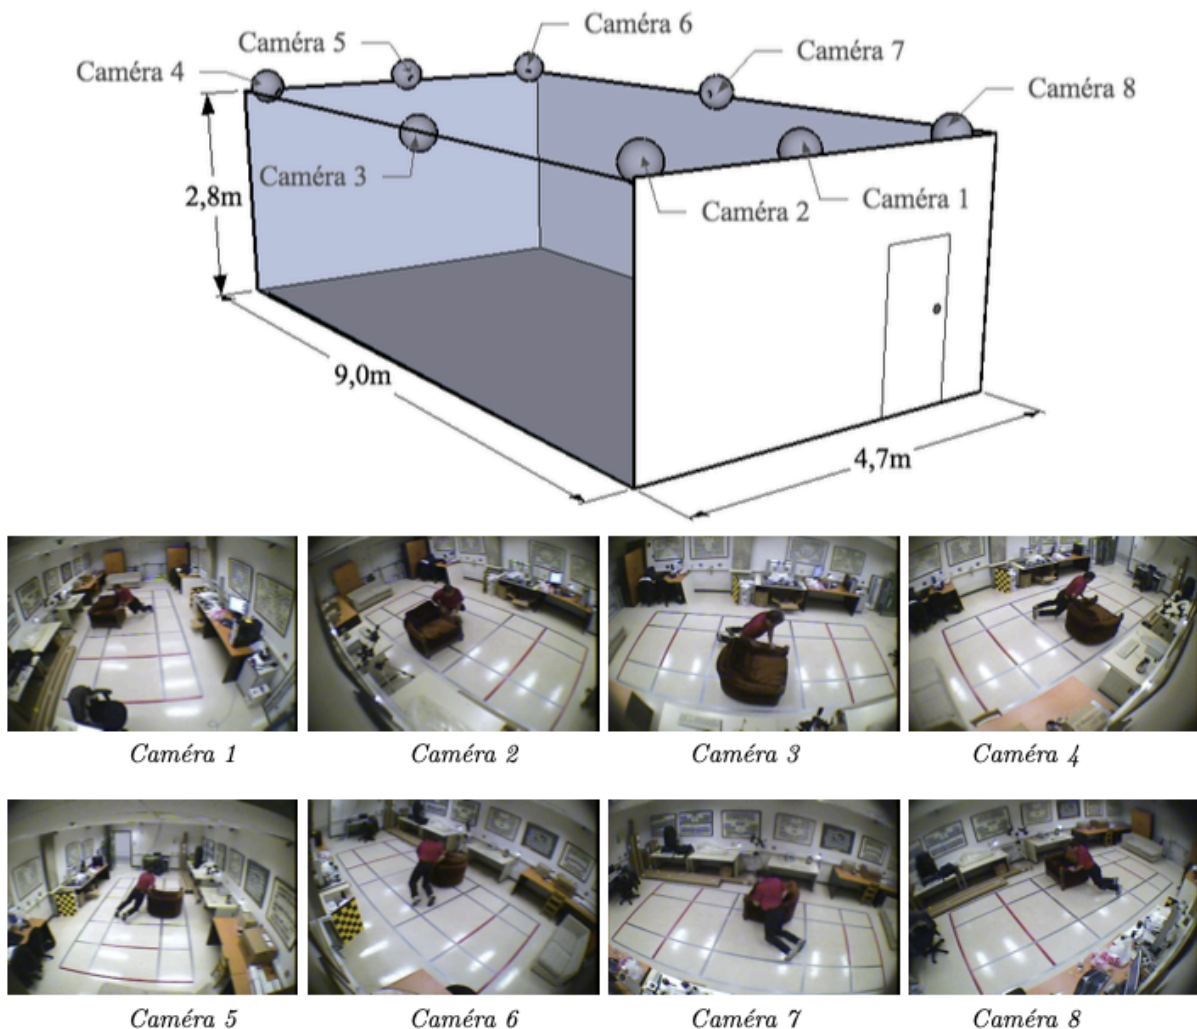


Figura 1: Configuración de la cámaras y ejemplo de una caída desde el punto de vista de todas las posiciones

Las secuencias de video contenían dificultades típicas que pueden llevar a errores de segmentación como:

- Alta compresión de video (MPEG4) que puede producir artefactos en la imagen.
- Sombras y reflejos que pueden detectarse como objetos en movimiento durante un proceso de segmentación.
- Fondo desordenado y con textura.
- Iluminación variable que debe tenerse en cuenta durante el proceso de actualización del fondo.
- Objetos transportados (bolsos, ropa, etc.) que también deben tenerse en cuenta durante el proceso de actualización del fondo.
- Oclusiones (sillas, sofá, etc.).

- Entrada/salida del campo de visión.
- Ropa diferente con colores y texturas distintas.
- Ponerse y quitarse un abrigo.

El conjunto de datos de vídeo está compuesto por varias actividades diarias normales simuladas y caídas vistas desde todas las cámaras y realizadas por un sujeto. Algunos ejemplos se muestran en la Fig. 2.

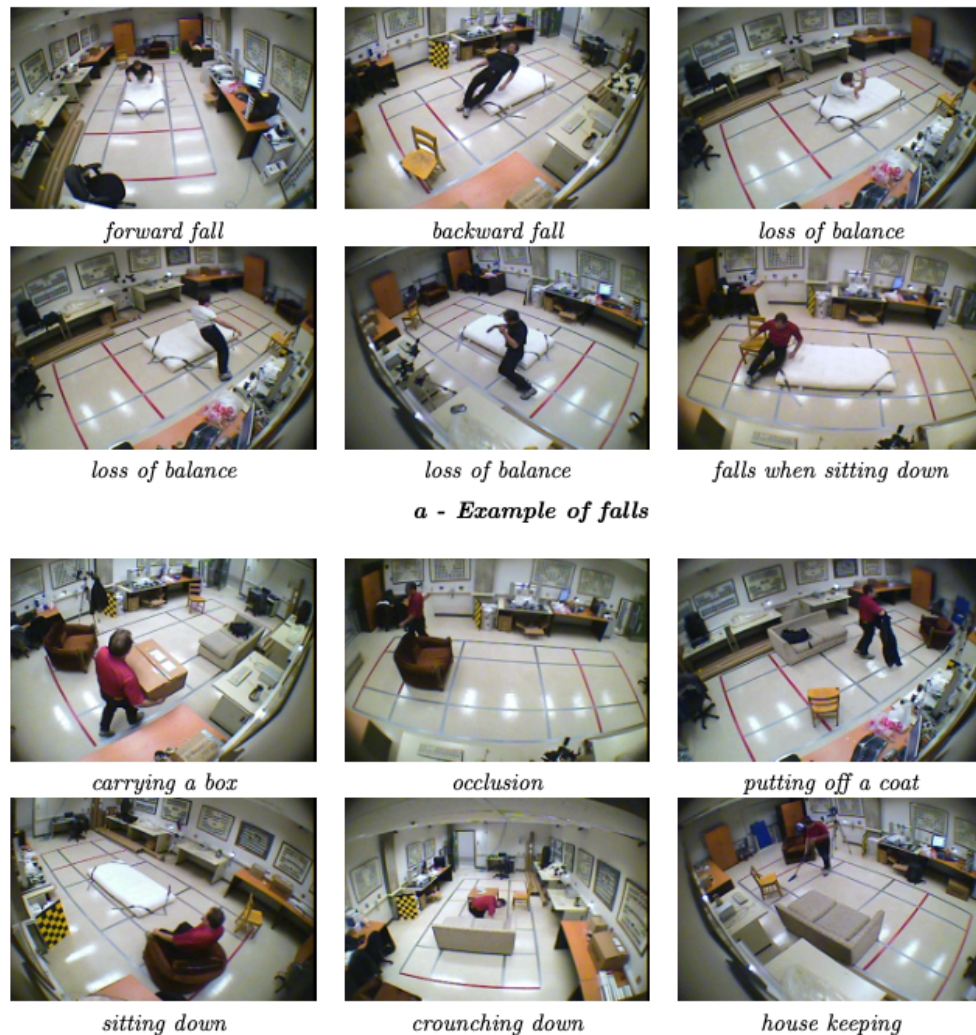


Figura 2: Ejemplos de Caídas y Actividades Normales

• **Actividades diarias normales** como caminar en diferentes direcciones, tareas domésticas, actividades con características similares a las caídas (sentarse/levantarse, agacharse). Pero también dificultades de procesamiento de imágenes como oclusiones u objetos en movimiento.

• **Caídas simuladas** como caídas hacia adelante, caídas hacia atrás, caídas al sentarse incorrectamente, pérdida de equilibrio. Las caídas se realizaron en diferentes direcciones con respecto al punto de vista de la cámara. Tomando en cuenta que se utilizó un colchón para proteger a la persona durante las caídas simuladas.

Parámetros del Dataset

Los parámetros intrínsecos se calcularon utilizando el método del tablero de ajedrez para definir la distancia focal $f=(f_x, f_y)$, el centro óptico $c=(c_x, c_y)$, el coeficiente de sesgo y la distorsión radial $k=(k_1, k_2, k_3, k_4, k_5)$ como se presenta en la figura 1. Estos últimos parámetros son necesarios debido a la distorsión radial no despreciable causada por el amplio campo de visión de las lentes de la cámara. Los parámetros extrínsecos, la matriz de rotación R y el vector de traslación T , se calcularon utilizando puntos característicos colocados manualmente en el suelo.

2. Análisis Exploratorio de Datos

En esta sección se presentan los datos del dataset, las muestras usadas para su generación y las correspondientes gráficas de análisis así como dar respuestas a las preguntas planteadas en la rúbrica del entregable correspondiente.

Los datos con los que se cuentan en el dataset de kaggle se generan a partir de **192** videos en formato AVI (Audio Video Interleave) en el que se generan en 28 grabaciones (chuts) como se describe continuación:

Disparo(2) (Chut)	Videos	Total Videos
24	8 videos (1 x Camará)	192

A partir de los videos obtenidos por las cámaras se identifican 5 datos para generar el set de análisis como se describe a continuación:

#	Feature	Descripción	Tipo
1	chut	Número de toma de video	Numérico Secuencial
2	cam	Número de cámara que está tomando el video (diferente ángulo)	Numérico
3	start	Numéro de frame de análisis donde inicia la caída	Numérico
4	end	Numéro de frame de análisis donde termina la caída	Numérico
5	fall	Detección de Caída 1/0 variable Target	Clase Binaria


Cada video contiene escenarios de comportamiento comunes que son grabados y a partir de los mismos se generan 552 muestras, para cada feature se presenta un análisis.

2.1 Análisis de Features

2.1.1 Chute Feature

chute

The chute number gives the id to a unique fall event in the dataset/dataset directory




Valid	552	100%
Mismatched	0	0%
Missing	0	0%
Mean	12.6	
Std. Deviation	7.02	
Quantiles	1	Min
	6	25%
	12	50%
	19	75%
	23	Max

2.1.1 Cam Feature

cam

Gives the camera number through which the fall event was recorded. There are 8 camera angles for each video




Valid	552	100%
Mismatched	0	0%
Missing	0	0%
Mean	4.59	
Std. Deviation	3.14	
Quantiles	1	Min
	3	25%
	5	50%
	7	75%
	55	Max

2.1.1 Start Feature

start


The starting frame of an event (fall/non-fall)



2.1.1 End Feature

end

The ending frame of an event (fall/non-fall)



Valid	552	100%
Mismatched	0	0%
Missing	0	0%
Mean	776	
Std. Deviation	613	
Quantiles	270	Min
	498	25%
	636	50%
	788	75%
	4.2k	Max

2.1.1 Label Feature

label

Fall: 1 and Non-Fall: 0



Valid	552	100%
Mismatched	0	0%
Missing	0	0%
Mean	0.48	
Std. Deviation	0.5	
Quantiles	0	Min
	0	25%
	0	50%
	1	75%
	1	Max

2.2. ¿Hay valores faltantes en el conjunto de datos? ¿Se pueden identificar patrones de ausencia?

En este caso no hay valores faltantes en el conjunto de datos. La sección sobre sincronización de cámaras explica cómo se manejaron los diferentes tiempos de inicio de grabación, calculando un retraso (delay) para cada cámara en cada escenario, pero esto no se considera un valor faltante, sino una característica del proceso de captura.

Sin embargo, para un proyecto de visión computacional, los "valores faltantes" pueden interpretarse de varias maneras:

- **Archivos corruptos o vacíos:** Videos que no se pueden abrir o imágenes que están dañadas.

- **Etiquetas faltantes:** Secuencias de video que no tienen una etiqueta clara de "Caída" o "Actividad Cotidiana" (ADL).
- **Marcos inutilizables:** Segmentos de un video donde el sujeto está fuera de cámara, la imagen está completamente oscura o muy borrosa.

Posible Plan de Acción:

1. **Crear un inventario:** Escribir un script (usando Python con OpenCV y Pandas) que recorra todos los archivos de video de tus datasets.
2. **Verificar la integridad:** Para cada archivo, intentar abrirlo y leer el primer cuadro. Si falla, márcalo como "corrupto". Registrar el nombre del archivo y el dataset de origen en un DataFrame de Pandas.
3. **Contar cuadros y duración:** Para los videos válidos, registrar la cantidad total de cuadros y la duración. Videos con muy pocos cuadros (ej. menos de 10) podrían ser anómalos o inútiles.
4. **Analizar patrones:** Una vez que tengamos este inventario, podríamos identificar si un dataset en particular (ej. "Multiple Cameras Fall Dataset") tiene más archivos corruptos que otros. Este es tu "patrón de ausencia".

2.3 ¿Cuáles son las estadísticas resumidas del conjunto de datos?

El dataset tiene **552 filas** y **5 columnas**: chute, cam, start, end, label.


chute: media ≈ 12.55 , rango [1, 23].

cam: media ≈ 4.59 , rango [1, 55], con mucha dispersión (desv. estándar ≈ 3.14).

start: media ≈ 746 , rango [240, 4166].

end: media ≈ 776 , rango [270, 4196].

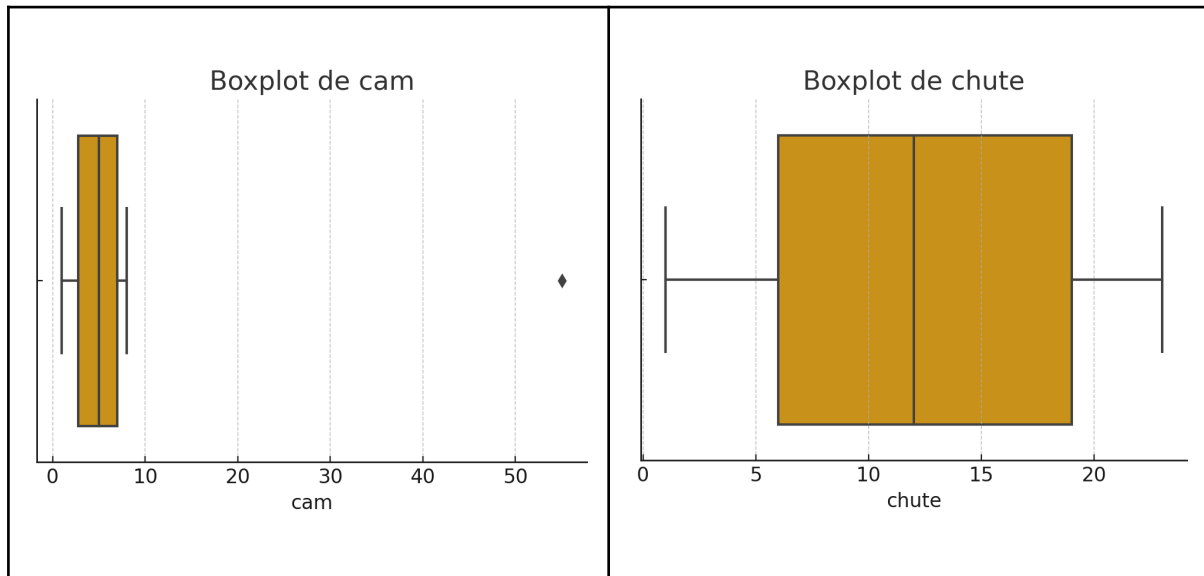
label: binaria (0 o 1), con media ≈ 0.48 .



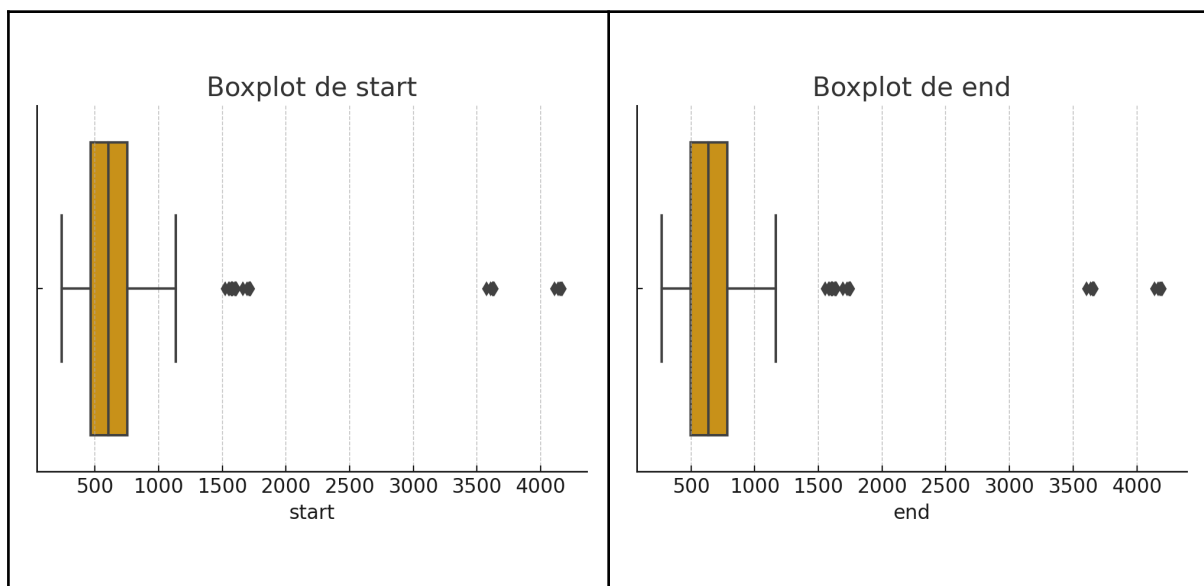
2.4. ¿Hay valores atípicos en el conjunto de datos?

Detectados con IQR:

cam: 1 valor atípico extremo (máximo 55), **chute y label:** sin outliers relevantes.



start y end: 40 outliers cada una (debido a valores mucho mayores al rango típico).



Para este set de datos los outliers no representan un problema ya que están basados en el número de inicio y fin de los frames.

2.5. ¿Cuál es la cardinalidad de las variables categóricas?

La principal variable categórica es la variable objetivo.

Variable Objetivo: La cardinalidad es 2. Las clases son:

0: Actividad Normal y 1: Caída Detectada. Esto define el problema como una clasificación binaria.

2.6. ¿Existen distribuciones sesgadas en el conjunto de datos? ¿Necesitamos aplicar alguna transformación no lineal?

En nuestro caso el conjunto de datos no se podría beneficiar de ninguna transformación, ya que lo importante es identificar las imágenes asociadas a las caídas y estas no están directamente asociadas con el número de frame donde aparecen.

2.7. ¿Se identifican tendencias temporales?

En este caso las variables start y end parecen representar secuencias o tiempos, pero sin un índice temporal explícito no es posible confirmar tendencias temporales.


Sin embargo en un escenario teórico se podría usar el siguiente plan de acción.

Plan de Acción:

1. **Extracción de Keypoints:** Usar un modelo pre-entrenado de YOLO-Pose para extraer los puntos clave del cuerpo (cabeza, hombros, cadera) en cada cuadro de algunos videos de ejemplo (uno de caída y uno normal).
2. **Visualización de Trayectorias:** Trazar la coordenada 'y' del centro de masa (o la cadera) de la persona a lo largo del tiempo (número de cuadro).
3. **Identificación de la Tendencia:**
 - En un video de actividad normal, la coordenada 'y' se mantendrá relativamente estable o cambiará lentamente.
 - En un video de caída, verás una caída súbita y pronunciada en la coordenada 'y'. Esta es la "tendencia temporal" clave que el modelo debe aprender.

2.8. ¿Hay correlación entre las variables dependientes e independientes?

1. **start y end:** correlación perfecta ($r = 1.0$) → son prácticamente duplicadas.
2. **chute:** correlaciona moderadamente con start/end ($r \approx 0.36$).
3. **label:** no muestra correlaciones fuertes con ninguna variable (máx. $r \approx 0.11$ con chute).



2.10. ¿Se deberían normalizar las imágenes para visualizarlas mejor?

Las imágenes y videos se encuentran normalizadas

2.11. ¿Hay desequilibrio en las clases de la variable objetivo?

Para nuestro dataset no tenemos desequilibrio.

1. label = 0: 52.2%
2. label = 1: 47.8%

Sin embargo en el mundo real, las caídas son eventos raros en comparación con las actividades normales este sería un plan de acción teórico.

1. **Cuantificar el Desequilibrio:** Calcular el número exacto de videos/secuencias para la clase Caída y para la clase No Caída. Presenta estos números y el ratio (ej. 5:1, 10:1).
2. **Explicar el Riesgo:** Un desequilibrio severo puede hacer que el modelo se vuelva "perezoso" y simplemente prediga la clase mayoritaria ("No Caída") la mayor parte del tiempo, logrando una alta precisión pero fallando en su objetivo principal de detectar caídas.
3. **Posibles Soluciones:**
 - Ponderación de Clases (Class Weighting): Asignar una penalización más alta en la función de pérdida cuando el modelo se equivoca en la clase minoritaria ("Caída"). Es el enfoque más común y efectivo.

- Técnicas de Remuestreo (Resampling): Sobremuestrear la clase minoritaria (Oversampling) o submuestrear la clase mayoritaria (Undersampling).
- Aumento de Datos Específico: Aplicar más técnicas de aumento de datos a las imágenes de la clase "Caída".

4. Planteamiento de Pruebas Finales

Para los datos de la validación hemos iniciado las primeras revisiones de potenciales escenarios para las pruebas una vez que lleguemos a la parte de las demostraciones hacia la parte final del proyecto.

Para dichas pruebas el equipo ha planteado las posibilidades de tener videos pregrabados por nosotros mismos en lugares designados de nuestros hogares y alimentarlos al modelo para que detecte las caídas; la otra opción es poder llevar a cabo la transmisión en vivo desde la cámara hasta la nube de IBM para poder realizar la inferencia en tiempo real.

En cualquiera de los casos debemos de preparar el lugar donde llevaremos a cabo las pruebas, seleccionar la cámara y los ángulos desde los cuáles se deberán tomar las muestras.

Se plantean los siguientes escenarios a continuación con la reserva de ajustar conforme lo requiera el proyecto.

4.1. Configuración de entorno de prueba

4.1.2 Ambientes domésticos representativos

Nosotros vamos a instrumentar 3 espacios: sala/comedor, dormitorio, pasillo/baño (lugares de alto riesgo). Utilizando algún colchón para simular las caídas.

Una vez realizadas las caídas guardaremos las grabaciones para ser utilizadas en las pruebas.

4.1.2. Cámaras y posiciones sugeridas

- Altura: 2,2–2,4 m, mirando ligeramente hacia abajo (~15–25°).
- Cobertura: FOV que incluya zona de tránsito y superficies donde se sienta/acueste (sillón, cama, pasillo).
- Fijamos marcas en el piso para garantizar misma posición entre corridas.
- Distancia a la zona objetivo: 3–5 m en sala; 2–3 m en dormitorio; 3–4 m en pasillos.
- Sin oclusiones evidentes (evitar lámparas de pie, plantas altas bloqueando). Esto garantiza consistencia entre repeticiones y maximiza la “visión amplia” esperada por el sistema.

4.1.3. Iluminación (condiciones de luz)

Nosotros vamos a ejecutar cada escenario en 5 condiciones:

1. Luz diurna difusa (cortinas abiertas, sin contraluz fuerte).

2. Contraluz (ventana detrás del sujeto).
3. Luz artificial cálida (3000–3500K).
4. Baja iluminación (noche, 1–2 luminarias a baja potencia).
5. Oscuridad parcial (pasillo con luz del dormitorio apagada/encendida alternadamente).

4.1.4. Red y latencia

Para el caso de llevar a cabo la prueba en línea se deberían de considerar los siguientes requerimientos mínimos de conectividad estable (≥ 10 Mbps upstream por cámara); simularemos jitter (± 50 –100 ms) para validar la latencia “captura→análisis→alerta”.

5. Bibliografía

1. Guardian Eye Project Team. (2025). *Project Guardian Eye: AI-Powered Monitoring for Safer Independent Aging* [Borrador de Propuesta Interna]. CONFIDENTIAL.
2. Sarker, S. (2022). *Multiple Cameras Fall Dataset* [Data set]. Kaggle. <https://www.kaggle.com/datasets/soumicksarker/multiple-cameras-fall-dataset>
3. Nikolov, I. (2022). *Thermal Mannequin Fall Image Dataset* [Data set]. Kaggle. <https://www.kaggle.com/datasets/ivannikolov/thermal-mannequin-fall-image-dataset>
4. Charfi, I., Miteran, J., Dubois, J., Atri, M., & Tourki, R. (2013). *Optimized spatio-temporal descriptors for real-time fall detection: Comparison of support vector machine and Adaboost-based classification*. *Journal of Electronic Imaging*, 22(4), 041106. <https://doi.org/10.1117/1.JEI.22.4.041106> Disponible en: <https://www.kaggle.com/datasets/tuyenldvn/falldataset-imvia>
5. Ariza-Colpas, P. P., Mendoza-Moreno, J. F., Carrillo-Ramos, A., & others. (2022). *CAUCAFall: A fall detection dataset with multiple actors, falls, and daily activities*. Universidad del Cauca. Disponible en: <https://data.mendeley.com/datasets/7w7fccy7ky/4>